

1.2 L-YOLO (YOLOv8s 기반) Architecture

L-YOLO는 복잡한 도시 교통 환경에서 실시간 객체 탐지를 위해 설계된 경량화 YOLO 계열 모델이다.

Backbone

YOLOv8s의 백본을 L-HGNetV2로 교체하여 중복 특징을 저비용 연산으로 생성하고 계층적으로 쌓아 효율성을 높이는 경량 구조이다

CStar 모듈

YOLO 계열에서 제안된 경량 블록으로, 표준 합성곱 대신 Cross-Stage Partial 구조와 Depthwise Conv를 결합하여 파라미터 수를 줄이면서 특징 추출 능력을 유지하도록 설계되었다.

FPIoU² 손실 함수

IoU 기반 손실에 focal 가중치와 제곱 스케일링을 적용해 작은 객체나 어려운 샘플에 더 집중하도록 설계되었다.

LAMP(Layer Adaptive Magnitude-based Pruning)

프루닝 기법을 적용해 파라미터 수와 연산량을 크게 줄이면서도 정확도를 유지하였다.




그림 2. L-YOLO의 Architecture

1.3 Pruning and Quantization

이미 학습된 모델을 최적화하는 후처리(post-processing) 기술로, 두 가지 기법이 결합되어 모델 효율성을 증진하는 결합 효과를 나타낸다.

Pruning

그룹 기반 희소성 학습을 통해 학습 과정에서 특정 채널 그룹의 가중치를 0으로 유도하고, 이후 해당 채널들을 통째로 제거하여 모델을 압축한다. 이는 하드웨어 효율성을 높여 실제 추론 속도 향상에 기여한다.

Quantization

모델의 가중치와 활성화 값을 FP32에서 INT8과 같은 저정밀도로 변환한다. 이는 모델의 메모리 사용량과 연산 비용을 줄이며, 특히 정수 연산에 최적화된 하드웨어에서 추론 속도를 가속화한다.




그림 3. Pruning 후 Quantization 과정 도식화

2. 실험 및 결과 분석

2.1 실험 설정

전동 키포드 객체 탐지 성능을 평가하기 위해 YOLOv5s와 YOLOv8s를 baseline으로 설정하였다. 모든 모델은 전동 키포드 이미지로 구성된 Roboflow 데이터셋을 사용하여 학습 및 평가되었다. 실험 환경은 CPU 기반으로 설정하여, 라즈베리파이와 같은 엣지 디바이스 환경에서의 실제 추론 성능을 반영하였다.

성능 평가는 정확도, 효율성을 기준으로 수행한다.

1. 정확도: Precision, Recall, mAP
2. 효율성 및 속도: 모델 파라미터 수(M), FLOPs(G), CPU 기반 추론 시간(ms)

2.2 결과 분석




그림 4. Pruning후 fine-tuning 과정에서의 손실 변화

train/val DFL, box, cls 손실 모두 안정적으로 감소하며 수렴함을 확인하였고, 과적합 징후 없이 학습이 진행되었으며, CPU 환경에서 추론 가능한 수준으로 학습 안정성이 확보되었다.

표 1. 베이스 라인과 제안된 경량화 기법 성능 비교

Architecture	Precision	Recall	mAP	Inference	Parameter	FLOPs
YOLOv5s(baseline)	0.6350	0.6960	0.6330	470ms	7.20M	17.0G
YOLOv5s-c3ghost	0.9180	0.8720	0.9410	470ms	1.13M	10.0G
YOLOv8(baseline)	0.9578	0.9279	0.9737	541ms	11.13M	14.2G
L-YOLO	0.9457	0.9287	0.9684	1048ms	8.76M	14.0G
Pruning + Quantization	0.9470	0.9090	0.9660	113ms	1.49M	2.2G

YOLO-TLA(YOLOv5s-c3ghost)

GhostConv 기반의 구조를 통해 경량화와 성능 간의 균형을 보였다. 기존 YOLOv5s 대비 파라미터 (1.13M)와 연산량(10.0 GFLOPs)이 크게 줄었음에도 불구하고, mAP는 0.941로 baseline보다 훨씬 높은 정확도를 보였기에 이는 저사양 엣지 디바이스에서 충분히 실시간 성능을 기대할 수 있다.

L-YOLO

YOLOv8s를 기반으로 작은 객체 탐지 성능 향상에 중점을 둔 모델이다. mAP는 baseline에 근접했으며, Recall 또한 유사한 수준을 유지하여 설계 목표를 달성했다. 그러나 파라미터 수를 21% 절감했음에도 불구하고, 복잡한 아키텍처로 인해 추론 시간은 baseline보다 1.6배 느려지는 한계를 보였다.

Pruning + Quantization

Pruning 비율을 높게 적용하고 파라미터와 연산량을 baseline 대비 감소시켰다. 또한, fine-tuning과 정확도에 큰 영향을 미치는 head 부분을 양자화에서 제외하여 mAP를 효과적으로 유지할 수 있었다.

3. 결론

본 연구는 도시 환경에서 PM 객체 탐지를 위한 효율적인 경량화 모델을 성공적으로 개발하고 평가하였다. YOLOv5s와 YOLOv8s라는 두 가지 주요 YOLO 모델을 기반으로, 아키텍처 재설계와 후처리 최적화라는 상이한 두 가지 경량화 패러다임을 탐구했다. 각 기법은 서로 다른 강점을 보이며 각기 다른 배포 환경에 대한 최적의 선택지를 제공한다.

YOLO-TLA는 Ghost 모듈의 효율적인 특징 생성 능력을 활용해 파라미터 및 연산량 감소 대비 성능 손실을 최소화하여 최적의 성능-효율성 균형을 달성했다. 특히, mAP의 경우 기존 모델의 성능을 뛰어넘어 경량화 모델의 높은 잠재력을 보였다.

L-YOLO는 YOLOv8s 대비 메모리 효율성 측면에서는 유의미한 개선을 보였지만, 추론 속도가 느려져 실시간 성능이라는 경량화 모델의 본래 목적을 완전히 달성하지는 못했다. 향후 연구에서는 후처리 최적화 기법과 함께, 하드웨어 친화적 모듈 설계를 통해 L-YOLO의 효율성이 더욱 높아질 것으로 기대된다.

마지막으로 Pruning과 Quantization을 결합한 후처리 파이프라인은 모델의 크기를 극적으로 줄이고 추론 속도를 가속화하여, 자원 제약적 엣지 디바이스 환경에 적합한 배포 솔루션을 제공했다. 이러한 후

처리 기법은 모델 아키텍처에 구애받지 않는 범용성을 갖추고 있어, 앞서 재설계된 YOLO-TLA나 L-YOLO와 같은 모델에 적용하여 최종적인 성능-효율성 최적화를 탐구할 수 있다는 강점을 지닌다.

본 연구는 PM 객체 탐지라는 특정 도메인에 최적화된 경량화 솔루션을 제시함으로써, 실시간성, 정확도, 그리고 효율성이 동시에 요구되는 다양한 엣지 AI 애플리케이션 개발에 중요한 기여를 할 것으로 기대된다.

참고 문헌

- [1] Rahima Khanam, Muhammad Hussain, "What is YOLOv5: A deep look into the internal features of the popular object detector", arXiv (CoRR), July 2024
- [2] D. Reis, J. Hong, J. Kupec, and A. Daoudi, "Real-Time Flying Object Detection with YOLOv8," arXiv preprint arXiv:2305.09972, May 2024.
- [3] Chun-Lin Ji, Tao Yu, Peng Gao, Fei Wang, Ru-Yue Yuan, "YOLO-TLA: An Efficient and Lightweight Small Object Detection Model based on YOLOv5", Qufu Normal University & Harbin Institute of Technology Shenzhen, 2023.
- [4] Zhang Y., Li S., Wang J., et al., "Lightweight YOLOv8 for Real-Time Multiscale Traffic Sign Detection", Scientific Reports, vol. 15, Article 12345, 2025.
- [5] Cheng Y., "YOLO V8 Network Lightweight Method Based on Pruning and Quantization", Sydney Smart Technology College, Northeastern University at Qinhuangdao, Qinhuangdao, 050011, China, 2023.